

isChecker : regex VS modèle de langage

Rapport d'analyse des tests unitaires

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Le logiciel **isChecker** permet de vérifier le respect d'un ensemble de règles dans le cadre de la rédaction de documents techniques. Cette vérification repose actuellement exclusivement sur l'utilisation d'expressions régulières (**regex**), dans une implémentation codée en **Java**.

L'objectif de cette étude est d'explorer l'amélioration potentielle de cet outil en testant le remplacement, total ou partiel, des regex par un modèle de langage (**LLM**). Ici c'est le modèle **Llama-3.3-70b-instruct** qui a été évalué.

Les tests réalisés ont permis de comparer la capacité du modèle à détecter les violations de règles linguistiques dans des phrases données **par rapport au système existant**.

Périmètre des tests :

- 57 règles linguistiques couvertes,
- 11 catégories de règles,
- 1961 tests unitaires réalisés.

1961

Total Tests

1585

Total Positifs

19,17 %

Mesure Taux d'erreur

57

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Dans le cadre de cette étude, trois indicateurs clés de performance (**KPI**) ont été suivis :

- **Nombre total de tests** : 1961,
- **Nombre de tests positifs, c'est-à-dire identification correcte de la présence (ou non) d'erreurs dans les textes analysés** : 1585,
- **Taux d'erreur global par rapport aux résultats fournis par isChecker** : 19,17 %.

Ces résultats montrent que, dans l'ensemble, **le modèle LLM parvient à reproduire ou approcher les résultats obtenus par l'utilisation des regex**. On constate cependant que près d'un cinquième des cas entraînent une détection erronée ou une absence de détection. Plusieurs facteurs, abordés après dans ce rapport, peuvent expliquer ces chiffres.

Il est à noter que dans certains cas la testeuse était en **désaccord avec le résultat du logiciel isChecker** et en accord avec celui de modèle. Les résultats montrés ici sont une comparaison avec les performances du logiciel existant, lui-même susceptible de commettre des erreurs. **Une vérification par un(e) spécialiste de la langue française pourrait permettre une meilleure évaluation des capacités du modèle.**

- 1 - Présentation
- 2 - Vue Globale
- 3 - Analyse par Catégorie
- 4 - Analyse détaillée par catégorie
- 5 - Conclusion

1961

Total Tests

1585


Total Positifs

19,17 %

Mesure Taux d'erreur

57

Nombre de règles



L'analyse par catégorie révèle une **forte hétérogénéité des performances**.

Le graphique ci-contre présente le **taux d'erreur par catégorie**, avec un code couleur selon les seuils :

- **Vert (< 10 %)** → les règles sont plutôt bien maîtrisées par le modèle,
- **Orange (10-20 %)** → les résultats sont mitigés et nécessitent un ajustement des règles et davantage de tests,
- **Rouge (> 20 %)** → ces règles sont problématiques et peu adaptées à une détection directe par un LLM.

Les catégories **Paragraphe**, **Note**, **Chiffre** et **Titre** affichent les taux d'erreur les plus bas, ce qui démontre que le LLM gère correctement ces règles structurées. Des ajustements mineurs dans la formulation des règles pourraient permettre de réduire les taux d'erreur.

À l'inverse, les catégories **Unité (de mesure)**, **Alerte** et **Phrase** présentent des taux d'erreur élevés, ce qui peut suggérer plusieurs points :

- Problème d'interprétation du modèle,
- Problème dans la rédaction des règles,
- Incapacité du modèle à traiter certaines règles (par exemple, les règles nécessitant de compter des mots ou des phrases affichent pour certaines un taux d'erreur de 100%).

1961

Total Tests

1585

Total Positifs

19,17 %

Mesure Taux d'erreur

57

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie


5 - Conclusion

Ce diagramme permet de compléter l'analyse en montrant la **répartition du volume de tests par catégorie**. Ces données sont utiles pour relativiser un taux d'erreur, haut ou bas, sur une catégorie faiblement testée.

Dans la catégorie **Paragraphe** par exemple, seuls 3 tests ont été réalisés pour 1 seule règle. L'échantillon n'est pas assez représentatif pour juger avec fiabilité des capacités du modèle.

A l'inverse, la catégorie **Phrase** a été testée extensivement avec 851 tests réalisés pour 17 règles.

Volume de tests par Catégorie



1961

Total Tests

1585

Total Positifs

19,17 %

Taux d'erreur

57

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

30

Total Tests

23

Total Positifs

23,33 %

Taux d'erreur

1

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 1 règle,
- 30 tests,
- Taux d'erreur : 23,33 % - majoritairement des faux négatifs (violation non détectées).

Observations

- La règle est plutôt sémantique car nécessite une identification de la nature de l'échantillon testé (injonction d'avertissement ou non),
- Le LLM a des **difficultés à identifier correctement une consigne d'avertissement**,
- L'utilisation de tags différents - *warning*, *caution* - a perturbé son interprétation des échantillons testés et par conséquent affecte les résultats.

Bilan & recommandations

- Faire preuve de plus de précision dans la rédaction de la règle,
- Fournir des exemples négatifs et positifs concrets,
- Limiter à un seul tag lors du pré-traitement du document.

140

Total Tests

133

Total Positifs

5,00 %

Taux d'erreur

4

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 4 règles
- 140 tests (24 à 41 échantillons par règle)
- Taux d'erreur : 5,00 %

Observations

- Le LLM s'est montré **très performant sur ces règles**, malgré un volume de tests moyen pour chacune il comprend et interprète correctement les consignes données,
- Les erreurs sont concentrées sur les formats de milliers et séparateurs décimaux, des concepts peut-être plus difficiles à traiter pour un modèle non francophone utilisant une convention d'écriture différente,
- Dans certains cas **le LLM semble avoir raison contrairement à isChecker** (ex. *Vérifier que la valeur est 123.3456*. où le LLM détecte correctement l'utilisation d'un point à la place d'une virgule comme séparateur décimal).

Bilan & recommandations

- Fournir des exemples négatifs et positifs pour illustrer les cas d'exclusion, notamment dans le cadre d'unités de mesure,
- Valider les résultats du LLM par rapport à la règle elle-même et non en comparaison avec isChecker.

33

Total Tests

29

Total Positifs

12,12 %

Taux d'erreur

6

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 6 règles
- 33 tests (2 à 19 échantillons par règle)
- Taux d'erreur : 12,12 %

Observations

- **Une seule règle**, qui est aussi celle ayant le plus d'échantillons, **présente des erreurs**,
- Le taux global est donc un peu élevé alors que **le LLM s'est montré très performant pour les autres règles** (0,00% d'erreur),
- Le LLM pourrait facilement remplacer l'utilisation des regex.

Bilan & recommandations

- ➡ Effectuer davantage de tests pour obtenir des résultats plus représentatifs,
- ➡ Consolider la règle la plus sensible (*ListWithIntroductorySentenceRegex*) pour réduire les erreurs résiduelles.

117

Total Tests

115

Total Positifs

1,71 %

Taux d'erreur

2

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 2 règles
- 117 tests (24 à 93 échantillons par règle)
- Taux d'erreur : 1,71 %

Observations

- **Excellents résultats,**
- Le LLM n'a fait qu'une erreur pour chacune des deux règles testées.

Bilan & recommandations

- Améliorer la rédaction des règles pour viser un taux d'erreur nul,
- Effectuer davantage de tests sur la règle *GIFASNoActionInNote* pour confirmer les performances du LLM.

3

Total Tests

3

Total Positifs

0,00 %

Taux d'erreur

1

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 1 règle
- 3 tests
- Taux d'erreur : 0,00 %

Observations

- Excellent résultat mais **à nuancer**,
- Il a fallu plusieurs interactions avec le LLM pour qu'il parvienne à compter correctement le nombre de phrases,
- **Trop peu de tests réalisés** pour évaluer de manière fiable les performances du LLM.

Bilan & recommandations

➡ Effectuer davantage de tests sur la règle *GIFASParagraphSentenceCount* pour confirmer les performances du LLM.

851

Total Tests

629

Total Positifs

26,09 %

Taux d'erreur

17

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 17 règles
- 851 tests (6 à 115 échantillons par règle)
- Taux d'erreur : 26,09 %

Observations

- Les résultats présentent une **forte variabilité**,
- Excellents résultats pour certaines règles : *CondPhrasing* (0 %), *ConjunctionBeforeVerb* (2,61 %),
- Échec complet pour d'autres : *GIFASTokenCount* (100 %), *MaxNumberOfWordsPerSentence* (100 %),
- Difficultés notables pour : *BracketsContentInfo* (39,06 %), *GIFAS1InfoMax* (59,18 %), *TooManyClausesNoGerund* (59,78 %).

Bilan & recommandations

- Certaines règles nécessitent d'être testées plus extensivement,
- Le LLM montre de vraies limites sur les règles quantitatives (longueur, nombre de tokens ou de mots par phrase), mais se montre beaucoup plus performant sur les règles de logique linguistique (conditions, conjonctions),
- C'est la catégorie la plus représentative de l'**intérêt d'une approche hybride regex + LLM**.

122

Total Tests

106

Total Positifs

13,11 %

Taux d'erreur

5

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 5 règles
- 122 tests (6 à 58 échantillons par règle)
- Taux d'erreur : 13,11 %

Observations

- Le LLM reconnaît correctement la plupart des cas d'interdiction de ponctuation,
- **3 règles avec un taux d'erreur nul** confirme une bonne maîtrise du modèle sur les cas les plus simples,
- Les erreurs sont concentrées sur certaines variantes comme *GIFASProhibitedPunctuation* (17,95 % d'erreurs).

Bilan & recommandations

- Réaliser davantage de tests pour certaines règles,
- Une approche hybride ou full LLM est possible, mais compte tenu du caractère très factuel de ces règles **les regex sont l'option fiable**.

58

Total Tests

55

Total Positifs

5,17 %

Taux d'erreur

9

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 9 règles
- 58 tests (2 à 16 échantillons par règle)
- Taux d'erreur : 5,17 %

Observations

- 8 règles sur les 9 sont validées sans aucune erreur,
- La seule difficulté concerne la règle *MaxNumberOfWordsPerSentenceTitle* (60 % d'erreurs).

Bilan & recommandations

- Les règles nécessitent d'être testées plus extensivement pour consolider les résultats,
- Comme pour la catégorie *Phrase*, le LLM échoue sur les règles quantitatives (comptage de mots) : les regex sont préférable pour ce type de règle.

81

Total Tests

63

Total Positifs

22,22 %

Taux d'erreur

1

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 1 règle
- 81 tests
- Taux d'erreur : 22,22 %

Observations

- Des erreurs notables apparaissent dans la reconnaissance d'unités correctes,
- Le LLM confond parfois les notations ou n'applique pas strictement la norme attendue (ex. normes québécoises utilisées dans la première série de tests).

Bilan & recommandations

- Fournir davantage d'exemples positifs et négatifs au LLM pour clarifier les attentes,
- Spécifier précisément les normes de référence,
- Privilégier les regex pour ce type de règle, car il s'agit de formats strictement normalisés.

245

Total Tests

197

Total Positifs

19,59 %

Taux d'erreur

7

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 7 règles
- 245 tests (9 à 68 échantillons par règle)
- Taux d'erreur : 19,59 %

Observations

- Les résultats présentent une variabilité selon les règles,
- Le LLM obtient de très bons résultats sur la règle *ModalForDirectives* (taux d'erreur 6,52 %),
- En revanche il se montre moins performant sur d'autres : *ProhibitedTensesForDirectives* (44,44 %), *GIFASProhibitedTenses* (32,14%) et *PresentParticiple* (29,17 %),
- Ces difficultés sont liées à la morphologie verbale et à la détections des temps interdits, qui nécessitent une analyse syntaxique fine.

Bilan & recommandations

- Réaliser davantage de tests pour renforcer l'évaluation de certaines règles,
- Le LLM est utile, mais manque de fiabilité pour remplacer complètement les regex.

281

Total Tests

232

Total Positifs

17,44 %

Taux d'erreur

4

Nombre de règles

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

Sélectionner une catégorie pour en voir les détails

Alerte

Chiffre

Liste

Note

Paragraphe

Phrase

Ponctuation

Titre

Unité

Verbe

Vocabulaire

Panel de test & résultats

- 4 règles
- 281 tests (51 à 92 échantillons par règle)
- Taux d'erreur : 17,44 %

Observations

- Le LLM reconnaît bien les formulations vagues ou inadéquates (moins de 15 % d'erreurs),
- En revanche il commet davantage d'erreurs sur la complexité phrastique (21,88 %) et surtout les mots non approuvés (25,68 %),
- Il a tendance à ne pas respecter strictement les listes de termes, identifiant parfois des expressions non données mais avec des similarités lexicales.

Bilan & recommandations

- Le LLM est intéressant car il saisit des nuances de style qu'une regex ne peut pas capter,
- Mais il reste imprécis pour les listes fermées de termes interdits où les regex se montrent plus fiables.

1 - Présentation

2 - Vue Globale

3 - Analyse par Catégorie

4 - Analyse détaillée par
catégorie

5 - Conclusion

La phase de tests a permis d'obtenir une première vision claire des forces et faiblesses du LLM Llama-3.3-70b-instruct dans le cadre d'une vérification de conformité rédactionnelle.

Certaines règles peuvent être traitées efficacement par des regex comme par le LLM, sans perte significative de performance. D'autres règles nécessitant une interprétation linguistique ou stylistique (**formulations ambiguës, nuances de sens, contexte particulier**) sont plus adaptées à une **approche LLM**, bien que les performances dans cette étude montrent des limites.

Un système **hybride regex + LLM** apparaît comme la voie la plus prometteuse : les regex assurant une détection robuste sur les structures simples, le LLM intervenant sur des règles plus contextuelles et subtiles.

Éléments positifs :

- Le LLM offre plus de flexibilité que les regex,
- Il permet de prendre en compte le contexte et les nuances linguistiques,
- Il peut traiter des règles complexes ou ambiguës que les regex ont du mal à gérer.

Points de vigilance :

- Taux d'erreur : un taux de **19,17 %** est trop élevé pour envisager une substitution complète,
- Qualité des prompts : les règles ont été rédigées par une personne non-spécialiste et à partir du système de regex parfois lui-même en difficulté sur certaines détections ; cela peut causer certaines erreurs dans l'analyse du modèle,
- Volume de tests : certaines règles ont été évaluées sur un nombre réduit de cas, limitant la robustesse statistique,
- Comportement : malgré l'utilisation d'un prompt système constant durant les semaines de tests, le modèle a adopté des comportements et des formats de réponse variables ; un LLM reste un outil externe que l'on ne peut contrôler et ses variations de comportement peuvent affecter la qualité des résultats.

Recommandations :

- Etendre les tests à un **corpus de données plus large** pour améliorer la représentativité des résultats,
- **Affiner la rédaction des règles** avec l'appui d'un linguiste technique,
- Étudier un **modèle hybride regex + LLM** pour combiner robustesse et flexibilité,
- Prioriser l'usage du LLM sur les catégories où il apporte une réelle **valeur ajoutée** (style, concision, ambiguïtés).